

同濟大學

TONGJI UNIVERSITY

实验报告

课题名称

大语言模型部署体验实验报告

副 标 题

基于 ModelScope DSW 的 Qwen2.5 系列问答测试与横向比较

学 院

计算机科学与技术学院

专 业

软件工程

学生姓名

臧真宇

学 号

2451412

指导教师

邓浩

2026 年 5 月

目 录

1	实验目的与作业要求	1
2	实验环境	1
3	模型部署过程	2
4	问答测试设计	2
5	模型问答结果	3
6	其他模型部署问题记录	5
7	横向对比分析	6
8	公开链接与截图材料	7
9	结论	8

1 实验目的与作业要求

本次作业要求在魔搭 ModelScope 平台上部署并测试大语言模型，提交公开可访问的项目链接，并完成实验报告。报告需要覆盖三个评分点：部署或 git clone 相关截图、问答测试结果截图，以及不同大语言模型之间的横向对比分析。

根据补充材料，推荐模型包括通义千问 Qwen、智谱 ChatGLM3、百川 Baichuan2 等。本次实验在实际部署中优先选择 ModelScope 上可稳定运行的中文指令模型，主实验采用 Qwen2.5 系列的不同参数规模模型，并补充记录 ChatGLM3-6B 与 Baichuan2-7B-Chat 在当前环境下遇到的兼容性问题。该安排既满足“2-3 个不同模型”的测试要求，也能比较参数规模、运行环境和回答质量之间的关系。

2 实验环境

实验主要在 ModelScope DSW 中完成。前期使用免费 CPU 实例验证环境和脚本，后续切换到 GPU 实例完成 7B 模型测试。表 1 给出本次实验中记录到的主要环境信息。

表 1 实验环境配置

项目	配置
平台	ModelScope DSW
CPU 实例	DSW-CPU, Python 3.11.11, PyTorch 2.3.1+cpu, transformers 4.55.4, modelscope 1.37.1
GPU 实例	DSW-GPU, NVIDIA A10, 显存约 23GB
工作目录	/mnt/workspace/hw3_llm_compare 与 /mnt/workspace/hw3_big_models
主要依赖	PyTorch、transformers、modelscope、accelerate 等
测试任务	中文歧义句、指代关系和多义词理解问答



图 1 ModelScope DSW GPU 实例运行截图

3 模型部署过程

实验通过 ModelScope 的 `snapshot_download` 或模型仓库下载接口将模型文件保存到工作目录下的 `models` 子目录，再使用 `transformers` 加载 `tokenizer` 和 `causal language model`。CPU 实例先用于小模型验证，GPU 实例用于 7B 模型推理。

本次成功完成问答测试的模型如表 2 所示。为满足作业中的横向比较要求，实验选择了同一模型家族的两个参数规模。这样可以减少模型架构差异带来的干扰，更清楚地观察参数规模和硬件环境对中文理解效果的影响。

表 2 成功完成测试的模型

模型	参数规模	运行环境	测试完成情况
Qwen2.5-0.5B-Instruct	0.5B	DSW-CPU	5 题完成
Qwen2.5-1.5B-Instruct	1.5B	DSW-CPU/GPU	2 题短测完成
Qwen2.5-7B-Instruct	7B	DSW-GPU	5 题完成

```

Downloading [model-00003-of-00004.safetensors]: 100%|██████████| 3.60G/3.60G [00:36<00:00, 106MB/s]
Downloading [model-00002-of-00004.safetensors]: 100%|██████████| 3.60G/3.60G [00:36<00:00, 106MB/s]
Downloading [model-00001-of-00004.safetensors]: 100%|██████████| 3.67G/3.67G [00:36<00:00, 107MB/s]
Processing 14 items: 100%|██████████| 14.0/14.0 [00:37<00:00, 2.65s/it]
2026-05-27 23:37:09,306 - modelscope - INFO - Finish downloading 14 files for repo 'Qwen/Qwen2.5-7B-Instruct'
2026-05-27 23:37:09,309 - modelscope - INFO - Creating symbolic link [./models/Qwen/Qwen2.5-7B-Instruct].
[transformers] `torch_dtype` is deprecated! Use `dtype` instead! 3.66G/3.67G [00:36<00:00, 166MB/s]
Loading weights: 100%|██████████| 339/339 [00:32<00:00, 10.53it/s].67G/3.67G [00:36<00:00, 169MB/s]
    
```

图 2 Qwen2.5-7B 模型下载与权重加载截图

4 问答测试设计

问答题主要来自作业补充材料，覆盖中文语义歧义、反讽表达、嵌套指代和多义词解释。五个测试问题如下：

1. 请说出以下两句话区别在哪里？1、冬天：能穿多少穿多少 2、夏天：能穿多少穿多少
2. 请说出以下两句话区别在哪里？单身狗产生的原因有两个，一是谁都看不上，二是谁都看不上
3. 他知道我知道你知道他不知道吗？这句话里，到底谁不知道？
4. 明明明明明白白白喜欢他，可她就是不说话。这句话里，明明和白白谁喜欢谁？
5. 领导：你这是什么意思？小明：没什么意思。意思意思。领导：你这就够意思了。小明：小意思，小意思。领导：你这人真有意思。小明：其实也没有别的意思。领导：那我就不好意思了。小明：是我不好意思。请问：以上“意思”分别是什么意思。

评价时主要关注三个维度：回答是否抓住语义差别，是否能处理中文上下文中的指代与省略，以及回答是否完整、清楚。由于本次实验不是训练模型，而是部署和推理体验，运行耗时也作为部署体验的一部分记录。

5 模型问答结果

5.1 Qwen2.5-0.5B-Instruct

0.5B 模型在 CPU 实例上完成了五个问题的推理。该模型参数量较小，部署和下载成本较低，但在 CPU 上推理速度很慢，并且复杂语义题的回答准确性不足。表 3 汇总了主要结果。

表 3 Qwen2.5-0.5B-Instruct 问答结果

题号	问题摘要	模型回答摘要	耗时
1	冬天与夏天“能穿多少穿多少”的区别	冬天不能穿太多衣服，夏天可以穿很多衣服	212.18 秒
2	“谁都看不上”的双重含义	认为第一句是没人喜欢，第二句是多个原因	629.80 秒
3	嵌套“知道/不知道”中谁不知道	他	63.49 秒
4	明明和白白谁喜欢谁	明明喜欢白白	109.20 秒
5	多个“意思”的语义解释	小明的意思是“我感觉不对劲”	207.72 秒

从结果看，0.5B 模型能够给出形式完整的回答，但容易忽略中文幽默和歧义的真正关键。例如第一题的正确理解应是冬天“尽量多穿”、夏天“尽量少穿”，但模型回答成“冬天不能穿太多衣服”。第五题也没有逐项解释“意思”的不同含义。



图 3 Qwen2.5-0.5B-Instruct 问答测试截图

5.2 Qwen2.5-1.5B-Instruct

1.5B 模型完成了两道短问答。与 0.5B 相比，该模型在短输入上响应明显更快，回答更简洁，但由于本次只保留了两道问题结果，主要作为中间规模的补充材料。

1.5B 模型的答案比 0.5B 更稳，但第一题仍然偏概括，没有直接指出“冬天多穿、夏天少穿”的反向含义。因此，它适合快速验证部署流程，但不如 7B 模型适合复杂语义理解测试。

表 4 Qwen2.5-1.5B-Instruct 短问答结果

题号	问题摘要	模型回答	耗时
1	冬天与夏天“能穿多少穿多少”的区别	季节不同，穿衣自由度不同。	1.10 秒
2	嵌套“知道/不知道”中谁不知道	他。	0.54 秒




图 4 Qwen2.5-1.5B-Instruct 短问答截图

5.3 Qwen2.5-7B-Instruct

7B 模型在 GPU 实例上完成五题测试。相比 CPU 上的小模型，7B 模型不仅速度更快，答案也更接近中文语义理解任务的预期。表 5 给出主要结果。

表 5 Qwen2.5-7B-Instruct 问答结果

题号	问题摘要	模型回答摘要	耗时
1	冬天与夏天“能穿多少穿多少”的区别	冬天多穿衣服保暖，夏天少穿衣服散热，核心区别是季节和穿衣目的不同	3.08 秒
2	“谁都看不上”的双重含义	指出原句重复同一原因，并给出更合理的表达方式	2.74 秒
3	嵌套“知道/不知道”中谁不知道	认为“他”不知道前面的内容	2.71 秒
4	明明和白白谁喜欢谁	白白喜欢他，即白白喜欢明明	0.84 秒
5	多个“意思”的语义解释	逐项解释含义、客套、礼节、小事、有趣、意图、尴尬或抱歉等含义	11.59 秒

7B 模型在第一题和第五题上优势明显。第一题能够准确识别同一句式在不同季节中的反向含

义，第五题能够逐条解释“意思”在不同语境中的含义。第四题中模型将“他”理解为明明，虽然句子本身存在一定歧义，但回答逻辑比小模型更清楚。



图 5 Qwen2.5-7B-Instruct 问答测试截图

6 其他模型部署问题记录

除 Qwen2.5 系列外，本次还尝试了 Baichuan2-7B-Chat 和 ChatGLM3-6B。两个模型均能完成下载或部分加载，但推理阶段与当前 transformers 环境存在兼容性问题，因此未作为主对比模型。

6.1 Baichuan2-7B-Chat

Baichuan2-7B-Chat 的权重文件下载和加载过程能够完成，但调用 `model.chat` 或 `model.generate` 时出现缓存结构不兼容。日志中的核心错误为：

```
TypeError: 'DynamicCache' object is not subscriptable
```

该错误说明模型仓库中的旧版 `remote code` 仍按旧格式访问 `past_key_values`，而当前 transformers 版本返回的是新版 `DynamicCache` 对象。后续尝试切换静态缓存后，又出现 `StaticCache` 访问问题和 `meta tensor` 复制问题。因此本次报告将 Baichuan2 记录为“加载成功、推理失败”的兼容性案例。

6.2 ChatGLM3-6B

ChatGLM3-6B 的下载过程完成，但在当前环境下连续遇到多个 API 兼容问题，包括 `max_length`、`all_tied_weights_keys`、`batch_encode_plus`、`num_hidden_layers`、`_extract_past_from_model_output` 等属性或方法缺失。它们都指向同一个原因：ChatGLM3 的旧版自定义模型代码与当前 transformers 4.55.4 的接口不完全一致。

从部署体验角度看，这类问题说明大语言模型部署不仅取决于模型权重能否下载，也取决于模型仓库代码、transformers 版本、PyTorch 版本和推理脚本之间的匹配关系。




图 6 Baichuan2-7B 兼容性错误日志截图

7 横向对比分析

表 6 对成功测试模型和尝试部署模型进行横向比较。

表 6 模型横向对比

模型	运行环境	是否成功	速度表现	质量与部署体验
Qwen2.5-0.5B-Instruct	CPU	成功	很慢，单题最长超过 10 分钟	下载成本低，但复杂语义理解较弱
Qwen2.5-1.5B-Instruct	CPU/GPU	成功	短题约 1 秒以内到 1 秒左右	比 0.5B 稳定，适合快速验证
Qwen2.5-7B-Instruct	GPU	成功	多数题数秒完成	语义理解最好，回答完整度最高
Baichuan2-7B-Chat	GPU	推理失败	未完成问答	旧 remote code 与新版缓存接口不兼容
ChatGLM3-6B	GPU	推理失败	未完成问答	多处 transformers API 兼容问题

从实验结果看，参数规模对中文复杂语义理解有明显影响。0.5B 模型虽然能够输出中文回答，但容易只抓住字面信息，不能稳定理解反讽、歧义和多义词。1.5B 模型在短问答中速度快，回答也更自然，但已有测试数量较少。7B 模型在 GPU 上运行速度可接受，并且能更准确地解释问题中的隐含语义，是本次实验中综合效果最好的模型。

硬件环境同样影响部署体验。0.5B 模型在 CPU 上也能运行，但推理时间很长；7B 模型在 GPU 上反而能在数秒内完成多数问题。这说明对于大语言模型部署，免费 CPU 资源适合完成流程验证，GPU 资源更适合进行正式问答测试。

兼容性方面，Baichuan2 和 ChatGLM3 的失败并不是模型文件缺失，而是模型自定义代码与当前依赖版本不匹配。实际部署时，应优先确认模型文档推荐的 transformers 版本，或选择当前平台已验证的模型版本。

8 公开链接与截图材料

作业要求提供项目公开可访问链接。本次实验采用 GitHub 公开仓库作为可访问项目链接：

公开链接：<https://github.com/yuyu-yu-yu/hw3-llm-modelscope>

该仓库已设置为公开，包含实验报告 PDF、 $\text{\LaTeX}$ 源文件、报告截图和中文 README，可用于核验本次 ModelScope DSW 大语言模型部署与问答测试过程。




图 7 GitHub 公开仓库页面截图

9 结论

本次实验完成了 ModelScope DSW 平台上的大语言模型部署与中文问答测试。Qwen2.5-0.5B、Qwen2.5-1.5B 和 Qwen2.5-7B 展示了不同参数规模下的明显差异：小模型部署成本低，但复杂中文理解能力不足；7B 模型在 GPU 上速度和质量更均衡，能够更好地处理歧义句、指代关系和多义词解释。

同时，ChatGLM3-6B 与 Baichuan2-7B-Chat 的部署尝试表明，大模型部署中的关键问题不仅是算力和模型大小，还包括依赖版本和模型自定义代码的兼容性。对于课程作业场景，选择平台当前支持良好的模型，可以更稳定地完成部署、测试和横向分析。